

Bienvenida y Ciclo de Vida de Data Science

Sesión 1: ¿de qué trata este curso?

Enrique Bolaños Abner Xocop

21 de julio de 2026

Veritas · Libertas · Iustitia

Agenda

- 1.** Presentaciones
- 2.** ¿Qué es Data Science?
- 3.** El curso
- 4.** Evaluación
- 5.** Política de AI
- 6.** Herramientas y setup
- 7.** Cierre

¿Quiénes somos?

Catedrático

- Enrique Bolaños
- enriquebolanos@ufm.edu

Auxiliar

- Abner Xocop
- axocop@ufm.edu

¿Y ustedes? Ronda rápida:

- Nombre
- Algo de datos o AI que les llame la atención
- Qué esperan poder hacer al final del semestre

Una definición práctica

Data Science: convertir datos en decisiones

Es la intersección de tres habilidades:

- **Programación:** adquirir, limpiar y transformar datos a escala
- **Estadística:** cuantificar la incertidumbre y no engañarnos
- **Conocimiento del dominio:** hacer las preguntas correctas

Ustedes ya traen la primera. Este curso construye las otras dos **sobre** su ventaja como programadores.


Data Science está en todas partes

- **Netflix / Spotify:** sistemas de recomendación
- **Bancos:** detección de fraude en tiempo real
- **Retail:** pronóstico de demanda e inventario
- **Salud:** diagnóstico asistido por imágenes
- **LLMs:** ChatGPT y Claude son, en el fondo, productos de datos

Y en Guatemala:

- Precios de café y clima: ¿cuándo vender la cosecha?
- Riesgo crediticio en microfinanzas
- Datos públicos: educación, salud, economía (Banguat, INE)

El ciclo de vida de un proyecto de datos



- No es lineal: los proyectos reales dan varias vueltas
- La mayor parte del tiempo se va en las etapas 2 y 3, no en la 4

El semestre en nueve módulos

Semanas	Módulo	Hito
1-2	Fundamentos y stack moderno (NumPy, Pandas, SQL)	
3-5	Estadística: MLE/MAP, inferencia, A/B testing	
5-7	EDA, features y primeros algoritmos	Parcial I
8-10	Algoritmos de ML desde cero y ensambles	Proyecto 1
11-12	Causalidad y aprendizaje no supervisado	Proyecto 2
13-15	Deep Learning con PyTorch	Parcial II
16	LLMs en la práctica: prompting, RAG, agentes	
17	Series de tiempo, MLOps y AI responsable	
Finales	Presentación del proyecto final	Proyecto Final

El cronograma completo, con las 31 sesiones y todas las fechas, está en el PDF del curso.

Cómo trabajamos: primero desde cero

Implementamos los algoritmos antes de usar la librería

- Naive Bayes, regresión, árboles: primero con NumPy, a mano
- Después scikit-learn, XGBoost y PyTorch como herramientas de producción
- Objetivo: que sepan **qué hay adentro** cuando algo falla

MÁS ALLÁ DEL CÓDIGO

Un data scientist que solo sabe llamar `.fit()` no puede explicar por qué su modelo se equivoca. El que entiende el algoritmo, sí.

Rubro de evaluación

Componente	Puntos	Detalle
Hojas de Trabajo (10)	20	2 pts c/u, semanales, sin quizzes
Parciales (2)	30	15 pts c/u, sin AI
Proyectos (2)	20	10 pts c/u
Proyecto Final	30	Equipos de 2–3, preguntas en vivo
Total	100	

- **HDTs:** se asignan martes, se entregan el martes siguiente
- **Proyectos:** cada uno tiene un lab en clase antes de la entrega

Fechas clave

Evento	Fecha
Parcial I	3 de septiembre
Entrega Proyecto 1 (EDA + modelo baseline)	11 de septiembre
Entrega Proyecto 2 (modelado completo)	16 de octubre
Parcial II	22 de octubre
Asignación Proyecto Final	29 de octubre
Presentación Proyecto Final	16–20 de noviembre

Las últimas dos semanas no tienen otros proyectos: son para el proyecto final.

AI: permitida, con reglas claras

Claude, ChatGPT y Copilot son parte del trabajo real: aprenderán a usarlas **sin dejar de aprender**.

Slot A: sin AI

La primera entrega de cada trabajo se hace **sin asistencia de AI**: construye los fundamentos que la industria evalúa.

Slot B: con AI y bitácora

Después pueden revisar con AI libremente, entregando una **bitácora**: qué preguntaron, en qué se equivocó el modelo y cómo lo verificaron.

Los parciales son sin AI. Evaluar y corregir la salida de un modelo es una habilidad que este curso también califica.

El stack del curso

Capa	Herramienta
Lenguaje	Python 3.11+ (entornos con uv)
Datos	NumPy, Pandas, SQL, Polars, DuckDB
Visualización	Matplotlib, Seaborn, Plotly
ML	scikit-learn, XGBoost, LightGBM
Deep Learning	PyTorch (GPU gratis en Colab)
LLMs	Hugging Face, Ollama
Entorno	Jupyter, VS Code, Git

Todo el stack es **gratuito y open source**.

Tarea para el jueves: instalar el entorno

1. Instalar uv (gestor de Python y paquetes):

```
# macOS / Linux  
curl -LsSf https://astral.sh/uv/install.sh | sh
```

```
# Windows (PowerShell)  
powershell -c "irm https://astral.sh/uv/install.ps1 | iex"
```

2. Instalar VS Code (code.visualstudio.com) y Git (git-scm.com)

3. Crear una cuenta en GitHub si no tienen

Verificar que todo funciona

En una terminal:

```
uv init prueba-ds  
cd prueba-ds  
uv add numpy jupyter  
uv run jupyter lab
```

Si se abre Jupyter en el navegador, están listos.

El jueves trabajamos con NumPy: traigan laptop con el entorno listo

¿Problemas con la instalación? Escribanle a Abner antes del jueves.

Cómo tener éxito en este curso

- **Vengan a clase:** el material se construye sesión sobre sesión
- **Practiquen algo cada semana:** las HDTs están diseñadas para eso
- **Pregunten temprano:** en clase, por correo, con el auxiliar
- **Usen AI para entender**, no para evadir: la diferencia se nota en los parciales
- **Empiecen los proyectos el día que se asignan**, no la víspera

Próxima clase

Jueves 23 de julio: NumPy

Cómputo vectorizado, broadcasting y por qué los loops son lentos

¿Preguntas?

enriquebolanos@ufm.edu • axocop@ufm.edu