

HDT 1: Pandas, SQL y DuckDB

Asignada: martes 28 de julio · Entrega: martes 4 de agosto, 23:59

Dataset

Palmer Penguins: 344 pingüinos de tres especies, con valores faltantes reales. Se carga desde la URL incluida en el notebook. El notebook también incluye una tabla con el nombre científico de cada especie, para los ejercicios de JOIN.

Instrucciones

- Completar las celdas marcadas con # ¿Qué va aquí? en HDT1.ipynb.
- Cada ejercicio incluye una verificación comentada: descomentar para comprobar el resultado.
- Entregar el notebook ejecutado de arriba a abajo (Restart & Run All). Un notebook que no corre completo pierde 0.5 pts.
- Trabajo individual. Entrega por el canal indicado en clase, a más tardar el **martes 4 de agosto a las 23:59**.
- Si falta DuckDB: `uv add duckdb` (o la celda de instalación del notebook).
- AI: resolver sin AI. Si se usó para entender un concepto, anotarlo en la mini-bitácora del final del notebook (no penaliza). Los parciales son sin AI.

Ejercicios y puntos (total: 2.0)

	Parte	Ejercicio	Pts
1	A · Pandas	Cargar y explorar: shape, dtypes, nulos por columna	0.10
2	A · Pandas	Limpieza mínima: eliminar filas incompletas y reportar cuántas se perdieron	0.15
3	A · Pandas	Máscaras y orden: pingüinos de Biscoe con masa mayor a 4500 g, ordenados	0.15
4	A · Pandas	groupby por especie y sexo con agg de dos funciones	0.20
5	A · Pandas	Columna derivada: proporción largo/profundidad del pico	0.20
6	A · Pandas	merge con la tabla de nombres científicos	0.20
7	B · DuckDB	SELECT / WHERE / ORDER BY: el ejercicio 3, en SQL	0.20
8	B · DuckDB	GROUP BY + HAVING: especies con masa promedio mayor a 4000 g	0.20
9	B · DuckDB	JOIN con la tabla de nombres científicos	0.20
10	B · DuckDB	Window function: ranking de masa dentro de cada especie, top 3	0.20
11	C · Criterio	En 3-4 líneas: ¿cuándo conviene Pandas y cuándo SQL? Con base en esta hoja	0.20

Anexo

Al final del notebook hay tres ejercicios de repaso de las sesiones 2 y 3:

- A1 (sesión 2): z-score sin loops.
- A2 (sesión 2): distancias con broadcasting.
- A3 (sesión 3): propinas por día y turno con groupby + agg.