

HDT 3: Inferencia, Naive Bayes y Regresión

Asignada: jueves 20 de agosto · Entrega: jueves 27 de agosto, 23:59

Datos

Tres fuentes, todas deterministas para que las verificaciones sean exactas:

- Un **experimento A/B** simulado con semilla fija: 50,000 visitantes por grupo.
- Un corpus de **mensajes de texto** etiquetados (spam / normal), escrito en el notebook: 16 para entrenar y 4 para probar.
- **diamonds** (seaborn): 53,940 diamantes con precio, quilates y cortes.

La hoja cubre las sesiones 6, 7 y 8/8.5: decidir con tests si un efecto es real, clasificar contando, y modelar con la recta que el MLE escoge.

Instrucciones

- Completar las celdas marcadas con # ¿Qué va aquí? en `HDT3.ipynb`.
- Cada ejercicio incluye una verificación comentada: descomentar para comprobar el resultado.
- Entregar el notebook ejecutado de arriba a abajo (Restart & Run All). Un notebook que no corre completo pierde 0.5 pts.
- Trabajo individual. Entrega por el canal indicado en clase, a más tardar el **jueves 27 de agosto a las 23:59**.
- Dependencias: `numpy`, `pandas`, `matplotlib`, `seaborn`, `scikit-learn`.
- AI: resolver sin AI. Si se usó para entender un concepto, anotarlo en la mini-bitácora del final del notebook (no penaliza). El Parcial I (3 de septiembre) es sin AI.

Ejercicios y puntos (total: 2.0)

	Parte	Ejercicio	Pts
1	A · Inferencia	Diferencia observada del A/B y su intervalo del 95 % a mano	0.15
2	A · Inferencia	Test de permutación desde cero: la función completa y su p-value	0.20
3	A · Inferencia	100 tests bajo H_0 : descubrimientos con $\alpha = 0,05$ y con Bonferroni	0.15
4	B · Naive Bayes	Bolsa de palabras: tokenizar, vocabulario y matriz de conteos	0.15
5	B · Naive Bayes	Entrenar contando (Laplace) y clasificar los 4 mensajes de prueba	0.20
6	B · Naive Bayes	Las palabras más informativas del modelo	0.15
7	C · Regresión	EDA mínimo de diamonds: la cola larga de price	0.20
8	C · Regresión	OLS a mano: $\text{price} \sim \text{carat}$ con ecuaciones normales y R^2	0.20
9	C · Regresión	Residuos con patología y el arreglo log-log	0.20
10	C · Regresión	Regresión múltiple: ¿cuánto mejora agregar depth y table?	0.20
11	D · Criterio	Significancia estadística vs práctica, y extrapolación, con sus números	0.20