CIENCIA DE DATOS · SECCIÓN A · SEGUNDO SEMESTRE 2026

Proyecto 2: Predecir y Agrupar

Asignado: martes 6 de octubre · Entrega: viernes 16 de octubre, 23:59 · 10 pts

El proyecto

Un notebook sobre un **dataset real** (puede ser el del Proyecto 1, mejorado) con las dos mitades del curso hasta hoy:

- Un **modelo que predice**: preparación sin fugas, validación honesta, un modelo tonto y uno simple de comparación, y un ensamble (bosque o boosting) con búsqueda de opciones razonada.
- Un **análisis sin respuestas**: grupos (clustering) o resumen de columnas (reducción), con cada grupo o eje **nombrado y descrito** en palabras del negocio.

Lo que sube la nota: que la parte sin respuestas **explique algo** de la parte que predice (por ejemplo, en qué segmento falla más el modelo).

Estructura del notebook

1. **Pregunta y datos**: qué se responde, de dónde salen los datos (procedencia explícita)
2. **Mirada rápida a los datos**: lo justo, sin repetir el Proyecto 1
3. **Preparación**: `ColumnTransformer` y `Pipeline`
4. **Modelos de comparación**: el tonto y uno simple, con validación
5. **Ensamble y búsqueda de opciones**: qué se probó, en qué rango y por qué
6. **Evaluación final**: el test se toca una vez; métrica justificada y dónde falla el modelo
7. **Análisis sin respuestas**: grupos o ejes, con nombres
8. **Conexión**: qué aporta la parte 7 a la parte 6
9. **Conclusiones y límites**: qué no se puede concluir

Rúbrica (10 pts)

Criterio	Pts	Qué buscamos
Preparación y validación	3	El test se toca una vez; nada se filtra al modelo
Búsqueda de opciones y ensamble	2	Opciones probadas con razón, no al azar
Métrica e interpretación	2	Por qué esa métrica; dónde se equivoca el modelo
Análisis sin respuestas	2	Cada grupo o eje con nombre y descripción
Límites	1	Qué no se puede concluir

Antes de entregar: seis preguntas

1. ¿Todo lo que se calcula con los datos (escalas, codificaciones, rellenos) está **dentro** del `Pipeline`, y el `Pipeline` dentro de la validación?
2. ¿Está escrito **por qué** esa métrica: qué error cuesta más?
3. ¿Hay un modelo tonto (siempre la clase más común) y uno simple para comparar?
4. ¿La búsqueda de opciones dice qué se probó, en qué rango y por qué?
5. ¿Cada grupo tiene **nombre y descripción** en palabras del negocio?
6. ¿Hay un párrafo con lo que **no** se puede concluir?

Un grupo sin nombre es un grupo que no interpretaron.

Errores que restan puntos

- **Elegir con el test**: probar veinte opciones midiendo en test y reportar la mejor. Ese número ya no dice nada sobre datos nuevos.
- **Creerle ciegamente al silhouette**: el puntaje sugiere, ustedes deciden.
- **Leer importancias como causas**: que una columna ayude a predecir no significa que moverla cambie el resultado.
- **Agrupar sin escalar**: la columna de números grandes arma los grupos sola.
- **Ensamble sin comparación**: un bosque sin un modelo simple al lado no demuestra nada.

Entrega y reglas

- Trabajo individual. Notebook ejecutado de arriba a abajo (Restart & Run All), por el canal indicado en clase, a más tardar el **viernes 16 de octubre, 23:59**.
- Dataset real con procedencia explícita. Si es el del Proyecto 1, decir qué se mejoró.
- AI permitida **con bitácora de colaboración**: qué se preguntó, qué se usó y qué se verificó. Un resultado sin bitácora ni procedimiento vale la mitad.
- La HDT 7 de esta semana es corta a propósito: la prioridad es este proyecto.